

Trabajo Final Probabilidad y Estadística - CEIA

August 19, 2026

Universidad de Buenos Aires

Especialización en Inteligencia Artificial

Probabilidad y Estadística para la Inteligencia Artificial

Nombre: Luis Jose Paredes Ramirez

Código: a2627

1 Enunciado

Siguiendo con la historia de Don Francisco, con el tiempo y gracias a los análisis de Matías, el pequeño comerciante de barrio cuenta hoy con 5 supermercados: ‘*Santa Ana*’, ‘*La Floresta*’, ‘*Los Cedros*’, ‘*Palermo*’ y ‘*Córdoba*’.

También Matías ha avanzado en la Especialización en Inteligencia Artificial. Un día Don Francisco le plantea algunas inquietudes adicionales:

1. Don Francisco quiere entender mejor la afluencia de clientes por mes del supermercado ‘*Santa Ana*’.
2. Más aún, Don Francisco no sabe si puede estar seguro de que la afluencia de clientes son las mismas en todos los supermercados o si hay alguno que se comporte mejor que los demás, y si alguna de las tiendas necesita más atención porque está recibiendo menos clientes que las de las otras.

Con base en lo anterior,

1. (2.5 puntos) Crear una simulación del número de clientes diarios que van a los almacenes de Don Francisco, usando distribuciones **Poisson**, entre los años 2023, 2024 y 2025. En cada fecha, el parámetro λ_t debe ser la suma de los siguientes efectos:

Efecto anual:

Año	Efecto
2023	1000
2024	1500
2025	2000

Efecto mensual:

Mes	Efecto
Enero	1000
Febrero	1500
Marzo	2000
Abril	2000
Mayo	2500
Junio	2500
Julio	3000
Agosto	2500
Septiembre	2500
Octubre	2000
Noviembre	1500
Diciembre	1000

Efecto diario:

Día	Efecto
Domingo	1000
Lunes	2000
Martes	3000
Miércoles	3500
Jueves	3000
Viernes	2000
Sábado	1000

Efecto por tienda:

Tienda	Efecto
Santa Ana	5000
La Floresta	2000
Los Cedros	3000
Palermo	1000
Córdoba	3000

- (2.5 puntos) Con base en los datos generados, determinen **intervalos de confianza empíricos** para el supermercado ‘*Santa Ana*’ en cada mes, para significancias del **95 %** y el **99 %**.
- (2.5 puntos) De igual manera, realicen pruebas **ANOVA** para determinar si los clientes esperados de todas las tiendas son iguales o no, con significancia del **95 %**.
- (2.5 puntos) Finalmente, identifiquen la tienda con **mayor promedio** y la tienda con **menor promedio** de clientes y realicen una **prueba de hipótesis** para determinar si la diferencia entre ellas es distinta de cero o no. Verifiquen si las tiendas identificadas corresponden a las tiendas con mayores y menores efectos.

1.1 Entregables

Deben realizar un informe en un documento **PDF**, en donde queden claros los siguientes aspectos:

1. Planteamiento de los problemas de investigación
2. Procesamiento realizado a los datos
3. Resultados encontrados
4. Análisis y conclusiones

Deben entregar también el **código** utilizado en el proceso.

¡Muchos éxitos!!

```
[1]: import numpy as np
import pandas as pd
from scipy import stats as st
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
from matplotlib.lines import Line2D

SEED = 42 # para reproducibilidad
rng = np.random.default_rng(SEED)
```

2 Punto 1

Crear una simulación del número de clientes diarios que van a los almacenes de Don Francisco, usando distribuciones **Poisson**, entre los años 2023, 2024 y 2025. En cada fecha, el parámetro λ_t debe ser la suma de los siguientes efectos:

```
[2]: # Año: Efecto
efecto_anual = {
    2023: 1000,
    2024: 1500,
    2025: 2000
}

# Mes: Efecto
efecto_mensual = {
    1: 1000, # Enero
    2: 1500, # Febrero
    3: 2000, # Marzo
    4: 2000, # Abril
    5: 2500, # Mayo
    6: 2500, # Junio
    7: 3000, # Julio
    8: 2500, # Agosto
    9: 2500, # Septiembre
    10: 2000, # Octubre
}
```

```

    11: 1500, # Noviembre
    12: 1000 # Diciembre
}

# Dia: Efecto
efecto_diario = {
    0: 2000, # Lunes
    1: 3000, # Martes
    2: 3500, # Miercoles
    3: 3000, # Jueves
    4: 2000, # Viernes
    5: 1000, # Sabado
    6: 1000 # Domingo
}

# Tienda: Efecto
efecto_por_tienda = {
    "Santa Ana": 5000,
    "La Floresta": 2000,
    "Los Cedros": 3000,
    "Palermo": 1000,
    "Cordoba": 3000
}

```

Definimos la variable aleatoria:

X_{ij} : el numero de clientes que van en la fecha i al almacen j

Asumiendo que el numero de clientes que van diariamente a los almacenes de Don Francisco son independientes, entonces $X_{ij} \stackrel{iid}{\sim} \text{Poisson}(\lambda_t)$

Se construye una fila por cada combinacion **fecha** $\times$ **tienda** desde el **2023-01-01** hasta el **2025-12-31**

```

[3]: # Fechas de simulacion
fechas = pd.date_range("2023-01-01", "2025-12-31", freq="D")
efectos = pd.DataFrame({"fecha": fechas})
efectos["anio"] = efectos.fecha.dt.year
efectos["mes"] = efectos.fecha.dt.month
efectos["dia"] = efectos.fecha.dt.day

# Efectos (enunciado)
efectos["ef_anual"] = efectos.anio.map(lambda x: efecto_anual[x])
efectos["ef_mensual"] = efectos.mes.map(lambda x: efecto_mensual[x])
efectos["ef_diario"] = efectos.dia.map(lambda x: efecto_diario[x%7])

# Producto cartesiano efectos x tiendas
efectos = efectos.merge(

```

```

    pd.Series(efecto_por_tienda, name="ef_tienda").rename_axis("tienda").
    ↪reset_index(),
    how="cross"
)

print(f"Total de dias simulados: {len(efectos['fecha'].unique())}. Rango:␣
    ↪({fechas.min().date()}, {fechas.max().date()})")
print(f"Total de observaciones: {efectos.shape[0]}")
efectos.head(10)

```

Total de dias simulados: 1096. Rango: (2023-01-01, 2025-12-31)

Total de observaciones: 5480

```

[3]:      fecha  anio  mes  dia  ef_anual  ef_mensual  ef_diario  tienda \
0 2023-01-01  2023    1    1      1000       1000       3000  Santa Ana
1 2023-01-01  2023    1    1      1000       1000       3000  La Floresta
2 2023-01-01  2023    1    1      1000       1000       3000  Los Cedros
3 2023-01-01  2023    1    1      1000       1000       3000   Palermo
4 2023-01-01  2023    1    1      1000       1000       3000   Cordoba
5 2023-01-02  2023    1    2      1000       1000       3500  Santa Ana
6 2023-01-02  2023    1    2      1000       1000       3500  La Floresta
7 2023-01-02  2023    1    2      1000       1000       3500  Los Cedros
8 2023-01-02  2023    1    2      1000       1000       3500   Palermo
9 2023-01-02  2023    1    2      1000       1000       3500   Cordoba

```

```

    ef_tienda
0      5000
1      2000
2      3000
3      1000
4      3000
5      5000
6      2000
7      3000
8      1000
9      3000

```

Para cada fila calculamos λ_t como:

$$\lambda_t = \text{efecto_anual}(\text{año}) + \text{efecto_mensual}(\text{mes}) + \text{efecto_diario}(\text{día de semana}) + \text{efecto_tienda}(\text{tienda})$$

y luego el numero de clientes se muestrea como $\text{clientes} \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda_t)$.

```

[4]: efectos["lambda_t"] = efectos.apply(
    lambda row: row.ef_anual + row.ef_mensual + row.ef_diario + row.ef_tienda,
    axis=1
)

```

```
# Los clientes se distribuyen segun la distribucion de Poisson(lambda_t)
# https://numpy.org/doc/stable/reference/random/generated/numpy.random.poisson.
  ↪html
efectos["clientes"] = rng.poisson(efectos["lambda_t"].to_numpy())

efectos.head(10)
```

```
[4]:      fecha  anio  mes  dia  ef_anual  ef_mensual  ef_diario  tienda \
0 2023-01-01  2023    1    1      1000        1000        3000  Santa Ana
1 2023-01-01  2023    1    1      1000        1000        3000  La Floresta
2 2023-01-01  2023    1    1      1000        1000        3000  Los Cedros
3 2023-01-01  2023    1    1      1000        1000        3000   Palermo
4 2023-01-01  2023    1    1      1000        1000        3000   Cordoba
5 2023-01-02  2023    1    2      1000        1000        3500  Santa Ana
6 2023-01-02  2023    1    2      1000        1000        3500  La Floresta
7 2023-01-02  2023    1    2      1000        1000        3500  Los Cedros
8 2023-01-02  2023    1    2      1000        1000        3500   Palermo
9 2023-01-02  2023    1    2      1000        1000        3500   Cordoba

      ef_tienda  lambda_t  clientes
0          5000      10000      10085
1          2000       7000       7103
2          3000       8000       7860
3          1000       6000       6062
4          3000       8000       7883
5          5000      10500      10462
6          2000       7500       7536
7          3000       8500       8485
8          1000       6500       6512
9          3000       8500       8599
```

Resultado P1.

Luego de la simulacion, nos quedamos con un conjunto de **5.480 observaciones** (1.096 días × 5 tiendas) de clientes que van a las distintas tiendas diaramente, siguiendo una distribucion $\sim \text{iid Poisson}(\lambda_t)$.

3 Punto 2

Con base en los datos generados, determinen **intervalos de confianza empíricos** para el supermercado ‘Santa Ana’ en cada mes, para significancias del **95%** y el **99%**.

```
[5]: def intervalo_confianza_empirico(x: np.array, confianza: float):
      """IC empírico via percentiles de la muestra (no asume normalidad)."""
      alpha = 1 - confianza
```

```

    lo, hi = np.percentile(x, [100*alpha/2, 100*(1-alpha/2)])
    return lo, hi

def resumen_mes(x: np.array):
    ic95_lo, ic95_hi = intervalo_confianza_empirico(x, 0.95)
    ic99_lo, ic99_hi = intervalo_confianza_empirico(x, 0.99)
    return pd.Series({
        "n": len(x),
        "media": x.mean(),
        "std": x.std(ddof=1),
        "ic95_lo": ic95_lo,
        "ic95_hi": ic95_hi,
        "ic99_lo": ic99_lo,
        "ic99_hi": ic99_hi,
    })

# filtramos los datos para el supermercado 'Santa Ana'
efectos_santa_ana = efectos[efectos['tienda'] == 'Santa Ana'].
    ↪reset_index(drop=True)

# Determinamos los intervalos de confianza 0.95 & 0.99 en cada mes para los
    ↪clientes de la tienda Santa Ana
resumen_santa_ana = (
    efectos_santa_ana
    .groupby("mes")["clientes"]
    .apply(resumen_mes)
    .unstack() # .pivot()
    .reset_index()
)

resumen_santa_ana

```

```

[5]:
   mes  n      media      std  ic95_lo  ic95_hi  ic99_lo  \
0    1  93.0  9804.655914  1020.997354  7932.600  11523.300  7863.880
1    2  85.0  10229.670588  1008.359304  8524.300  11972.600  8474.040
2    3  93.0  10814.677419  1026.739385  8989.000  12491.800  8971.000
3    4  90.0  10776.533333  1004.454620  8990.850  12404.075  8843.620
4    5  93.0  11308.870968  1012.869205  9479.300  12879.300  9419.560
5    6  90.0  11269.166667  1017.892339  9461.525  12888.500  9412.890
6    7  93.0  11809.086022   995.283002  10023.600  13352.900  9912.900
7    8  93.0  11295.967742  1010.766707  9478.400  13005.200  9427.520
8    9  90.0  11275.844444  1021.755527  9443.525  12986.275  9308.005
9   10  93.0  10812.000000   997.743389  9007.400  12482.400  8889.800
10  11  90.0  10288.288889  1010.677048  8488.700  11994.525  8430.795
11  12  93.0   9804.623656  1035.859609  7973.000  11487.600  7888.600

```

```

        ic99_hi
0    11661.980
1    12106.480
2    12593.980
3    12595.255
4    12983.980
5    12984.090
6    13453.140
7    13096.860
8    13137.865
9    12604.460
10   12049.090
11   11704.660

```

```

[6]: meses_map = {1: "Enero", 2: "Febrero", 3: "Marzo", 4: "Abril", 5: "Mayo", 6:
    ↪ "Junio",
        7: "Julio", 8: "Agosto", 9: "Septiembre", 10: "Octubre", 11:
    ↪ "Noviembre", 12: "Diciembre"}

fig, (ax99, ax95) = plt.subplots(1, 2, figsize=(14, 7), sharey=True)

paneles = [
    (ax99, "ic99_lo", "ic99_hi", "tab:blue", "Intervalo de confianza empirico
    ↪ 99%"),
    (ax95, "ic95_lo", "ic95_hi", "tab:orange", "Intervalo de confianza empirico
    ↪ 95%"),
]

for ax, col_lo, col_hi, color, titulo in paneles:
    for _, row in resumen_santa_ana.iterrows():
        y = row["mes"]
        ax.plot([row[col_lo], row[col_hi]], [y, y], color=color, alpha=0.9,
    ↪ linewidth=3, solid_capstyle="round")
        ax.plot(row["media"], y, "o", color="white", markeredgecolor=color,
    ↪ markeredgewidth=1.5, zorder=3)

        ax.set_xlabel("Clientes diarios")
        ax.set_title(titulo)
        ax.xaxis.set_major_formatter(mticker.StrMethodFormatter("{x:,.0f}"))
        ax.grid(axis="x", alpha=0.3)
        ax.legend(handles=[
            Line2D([0], [0], color=color, alpha=0.9, linewidth=3, label=titulo),
            Line2D([0], [0], marker="o", color="white", markeredgecolor=color,
    ↪ linestyle="", label="Media muestral")
        ], loc="lower right")

```




```

ax99.set_yticks(list(meses_map.keys()))
ax99.set_yticklabels(list(meses_map.values()))
ax99.set_ylabel("Mes")
ax99.invert_yaxis() # Enero arriba, Diciembre abajo

fig.suptitle("Santa Ana: intervalos de confianza empiricos de clientes diarios_
↳por mes (2023-2025)")
plt.tight_layout()
plt.show()

```



Resultado P2.

Para cada mes se calculó el intervalo de confianza **empírico** de los clientes diarios de ‘Santa Ana’ usando el método de percentiles sobre la muestra observada (percentiles $\alpha/2$ y $1 - \alpha/2$ de las 90-93 observaciones diarias que caen en ese mes a lo largo de 2023-2025), sin asumir normalidad.

Se observa que: - Los meses con mayor afluencia media (Julio, Agosto, Septiembre) presentan intervalos centrados en valores más altos, consistente con su mayor efecto mensual (λ base más alto). - El intervalo al 99% es, como es esperable, más ancho que el del 95% en todos los meses, ya que exige mayor cobertura de la distribución empírica. - Al ser Poisson con λ grande (aprox. 9.000-13.000 según el mes), la dispersión relativa es baja: los IC resultan relativamente angostos en términos porcentuales respecto a la media ($\sigma \approx \sqrt{\lambda}$).

4 Punto 3

De igual manera, realicen pruebas **ANOVA** para determinar si los clientes esperados de todas las tiendas son iguales o no, con significancia del **95%**.

Antes de empezar veamos empíricamente la media y varianza de la muestra con que trabajaremos

```
[7]: resumen_tiendas = (
    efectos.groupby("tienda")["clientes"]
    .agg(n="count", media="mean", std=lambda x: x.std(ddof=1))
    .reindex(list(efecto_por_tienda.keys())) # mantenemos el orden de
    ↪definicion
    .reset_index()
)
resumen_tiendas
```

```
[7]:
```

	tienda	n	media	std
0	Santa Ana	1096	10793.655109	1182.567982
1	La Floresta	1096	7794.527372	1193.798096
2	Los Cedros	1096	8792.375000	1190.732895
3	Palermo	1096	6792.137774	1186.703264
4	Cordoba	1096	8795.472628	1183.133705

Planteamos las hipótesis:

$$H_0 : \mu_{\text{Santa Ana}} = \mu_{\text{La Floresta}} = \mu_{\text{Los Cedros}} = \mu_{\text{Palermo}} = \mu_{\text{Cordoba}}$$


$$H_1 : \text{al menos una media difiere de las demas}$$

con $\alpha = 0.05$.

Antes de aplicar ANOVA realizamos los siguientes supuestos: - Cada evento es independiente - Con $n = 1096$ fechas por tienda y λ_t grande, la Poisson se aproxima a una normal por teorema central del limite - y homogeneidad de varianzas

```
[8]: orden_tiendas = resumen_tiendas.sort_values("media", ascending=False)["tienda"].
    ↪tolist()
datos_ordenados = [efectos.loc[efectos["tienda"] == t, "clientes"].values for t
    ↪in orden_tiendas]

fig, ax = plt.subplots(figsize=(9, 6))
ax.boxplot(datos_ordenados, tick_labels=orden_tiendas, showmeans=True)
ax.set_ylabel("Clientes diarios")
ax.set_title("Distribucion de clientes diarios por tienda (2023-2025)")
ax.yaxis.set_major_formatter(mticker.StrMethodFormatter("{x:,.0f}"))
ax.grid(axis="y", alpha=0.3)
plt.tight_layout()
plt.show()
```



```
[9]: grupos = [efectos.loc[efectos["tienda"] == t, "clientes"].values for t in efecto_por_tienda.keys()]

f_stat, p_anova = st.f_oneway(*grupos)
alpha = 0.05

print(f"ANOVA de un factor (tienda): F = {f_stat:.4f}, p-valor = {p_anova:.4g}")
if p_anova < alpha:
    print(f"p-valor < {alpha}: rechazamos H0. Al menos una tienda tiene un promedio de clientes distinto de las demas.")
else:
    print(f"p-valor >= {alpha}: no hay evidencia suficiente para rechazar H0.")
```

ANOVA de un factor (tienda): F = 1711.0172, p-valor = 0

p-valor < 0.05: rechazamos H_0 . Al menos una tienda tiene un promedio de clientes distinto de las demas.

Dado que se rechaza H_0 , aplicamos un test **post hoc de Tukey HSD** para identificar que pares de tiendas difieren entre si.

```
[10]: from statsmodels.stats.multicomp import pairwise_tukeyhsd

tukey = pairwise_tukeyhsd(efectos["clientes"], efectos["tienda"], alpha=0.05)
print(tukey.summary())
```

Multiple Comparison of Means - Tukey HSD, FWER=0.05

group1	group2	meandiff	p-adj	lower	upper	reject
Cordoba	La Floresta	-1000.9453	0.0	-1139.3523	-862.5382	True
Cordoba	Los Cedros	-3.0976	1.0	-141.5047	135.3094	False
Cordoba	Palermo	-2003.3349	0.0	-2141.7419	-1864.9278	True
Cordoba	Santa Ana	1998.1825	0.0	1859.7754	2136.5895	True
La Floresta	Los Cedros	997.8476	0.0	859.4406	1136.2547	True
La Floresta	Palermo	-1002.3896	0.0	-1140.7967	-863.9825	True
La Floresta	Santa Ana	2999.1277	0.0	2860.7207	3137.5348	True
Los Cedros	Palermo	-2000.2372	0.0	-2138.6443	-1861.8302	True
Los Cedros	Santa Ana	2001.2801	0.0	1862.873	2139.6872	True
Palermo	Santa Ana	4001.5173	0.0	3863.1103	4139.9244	True

Resultado P3.

- El ANOVA de un factor da $F \approx 1711$, $p \approx 0$, muy por debajo de $\alpha = 0.05$: **se rechaza H_0** . Por ende tenemos evidencia estadísticamente fuerte de que el promedio de clientes no es el mismo en todas las tiendas.
- El post-hoc de Tukey HSD muestra que **todos los pares de tiendas difieren significativamente entre si, excepto Cordoba vs. Los Cedros**, consistente con que ambas comparten el mismo efecto de tienda simulado (3000).
- El orden de medias observado, Santa Ana > Cordoba ~ Los Cedros > La Floresta > Palermo, coincide exactamente con el orden de los efectos por tienda definidos en la simulacion (5000, 3000, 3000, 2000, 1000).

5 Punto 4

Finalmente, identifiquen la tienda con **mayor promedio** y la tienda con **menor promedio** de clientes y realicen una **prueba de hipótesis** para determinar si la diferencia entre ellas es distinta de cero o no. Verifiquen si las tiendas identificadas corresponden a las tiendas con mayores y menores efectos.

```
[11]: tienda_max = resumen_tiendas.loc[resumen_tiendas["media"].idxmax(), "tienda"]
      tienda_min = resumen_tiendas.loc[resumen_tiendas["media"].idxmin(), "tienda"]

      media_max = resumen_tiendas.set_index("tienda").loc[tienda_max, "media"]
      media_min = resumen_tiendas.set_index("tienda").loc[tienda_min, "media"]

      print(f"Tienda con mayor promedio de clientes: {tienda_max} (media = {media_max:
      ↪, .2f})")
      print(f"Tienda con menor promedio de clientes: {tienda_min} (media = {media_min:
      ↪, .2f})")
```

Tienda con mayor promedio de clientes: Santa Ana (media = 10,793.66)

Tienda con menor promedio de clientes: Palermo (media = 6,792.14)

Planteamos el contraste de hipotesis para la diferencia de medias entre la tienda de mayor y la de menor promedio:

$$H_0 : \mu_{\max} - \mu_{\min} = 0$$

$$H_1 : \mu_{\max} - \mu_{\min} \neq 0$$

con $\alpha = 0.05$. Usamos un [t de Student](#) para comparar dos grupos independientes

```
[12]: clientes_max = efectos.loc[efectos["tienda"] == tienda_max, "clientes"].values
      clientes_min = efectos.loc[efectos["tienda"] == tienda_min, "clientes"].values

      t_stat, p_valor = st.ttest_ind(clientes_max, clientes_min, equal_var=False)
      diferencia_medias = clientes_max.mean() - clientes_min.mean()
      alpha = 0.05

      print(f"Diferencia observada de medias ({tienda_max} - {tienda_min}):_
        ↪{diferencia_medias:,.2f} clientes/dia")
      print(f"t = {t_stat:.4f}, p-valor = {p_valor:.4g}")

      if p_valor < alpha:
          print(f"p-valor < {alpha}: rechazamos H0. La diferencia de medias es_
            ↪significativamente distinta de cero.")
      else:
          print(f"p-valor >= {alpha}: no hay evidencia suficiente para rechazar H0.")
```

Diferencia observada de medias (Santa Ana - Palermo): 4,001.52 clientes/dia

t = 79.0732, p-valor = 0

p-valor < 0.05: rechazamos H0. La diferencia de medias es significativamente distinta de cero.

```
[13]: tienda_max_efecto = max(efecto_por_tienda, key=efecto_por_tienda.get)
      tienda_min_efecto = min(efecto_por_tienda, key=efecto_por_tienda.get)

      print(f"Tienda con mayor efecto simulado: {tienda_max_efecto} (efecto =_
        ↪{efecto_por_tienda[tienda_max_efecto]})")
      print(f"Tienda con menor efecto simulado: {tienda_min_efecto} (efecto =_
        ↪{efecto_por_tienda[tienda_min_efecto]})\n")

      print(f"Coincide la tienda de mayor promedio observado con la de mayor efecto:_
        ↪{tienda_max == tienda_max_efecto}")
      print(f"Coincide la tienda de menor promedio observado con la de menor efecto:_
        ↪{tienda_min == tienda_min_efecto}")
```

Tienda con mayor efecto simulado: Santa Ana (efecto = 5000)

Tienda con menor efecto simulado: Palermo (efecto = 1000)

Coincide la tienda de mayor promedio observado con la de mayor efecto: True
Coincide la tienda de menor promedio observado con la de menor efecto: True

Resultado P4.

- La tienda con **mayor promedio** de clientes diarios es **Santa Ana** (media $\sim 10.793,66$) y la de **menor promedio** es **Palermo** (media $\sim 6.792,14$).
 - El t de Student da $t \approx 79.07$, $p \approx 0$, muy por debajo de $\alpha = 0.05$. Por ende **se rechaza** H_0
 - Ambas tiendas identificadas coinciden exactamente con las de **mayor y menor efecto de tienda simulado** (Santa Ana = 5000, Palermo = 1000). De esta forma confirmamos que la simulacion refleja fielmente los efectos definidos y que la tienda en Palermo necesita mas atencion por recibir sistematicamente menos clientes que el resto.
-